合成数据主表

Method	CU (%) ↑	UA (%) ↑	ASR (%) ↓	Total Tool Calls
No Defense	76.0	54.8	35.6	990
PIGuard	82.7	76.0	14.4	1307
ProtectAI	81.7	82.7	8.7	1306
Progent	76.9	58.7	24.0	1136
DRIFT	75.0	70.2	16.3	835
DAFR	90.4	77.9	2.9	1348

使用 DeepSeek-v4-flash-0731，在相同的 104 个配对任务上评估；每种配置执行 104 次干净任务与 104 次攻击任务，工具接口及执行预算一致。

CU 为干净任务完成率，UA 为攻击条件下原任务完成率，ASR 为攻击者目标达成率，均以百分比表示。CU、UA 越高越好，ASR 越低越好。三项独立按环境状态判定。

Total Tool Calls 为全部 208 次执行的工具调用总数，包含被防御层拒绝的有效请求。