Overview of the Evaluated Datasets

Benchmark	Domains	Avg. Tools	Tasks			Reference Statistics	
			User	Injection*	Pairs	Avg. Traj.	Avg. App.
AgentDojo	4	18.35	71	35	585	4.01	1.37
ASB	10	3.00	51	40	204	—	—
Synthetic	6	6.00	104	3	104	—	—

三套数据集在本文实际评测范围内的概览。Domains 为环境或代理类别数；Avg. Tools 为每个用户任务可见的平均工具数，按用户任务加权，ASB 包含每次执行注入的一个攻击工具。User 为不同用户任务数；Injection* 为独立攻击任务或模板数；Pairs 为实际评测的任务—攻击组合数。Avg. Traj. 为每个用户任务的参考工具调用步数；Avg. App. 为参考轨迹涉及的不同应用/服务数。* AgentDojo、ASB 按环境/代理内的攻击任务 ID 去重；Synthetic 按三类攻击模板去重，并实例化为 104 个攻击场景，因此该列不直接比较攻击丰富度。参考统计取 AgentDojo 官方 ground_truth，应用/服务按工具所属客户端模块区分，均按用户任务平均。ASB 与合成数据尚无对应标准参考序列和应用映射，标为“—”。各行均为本文实际评测范围。