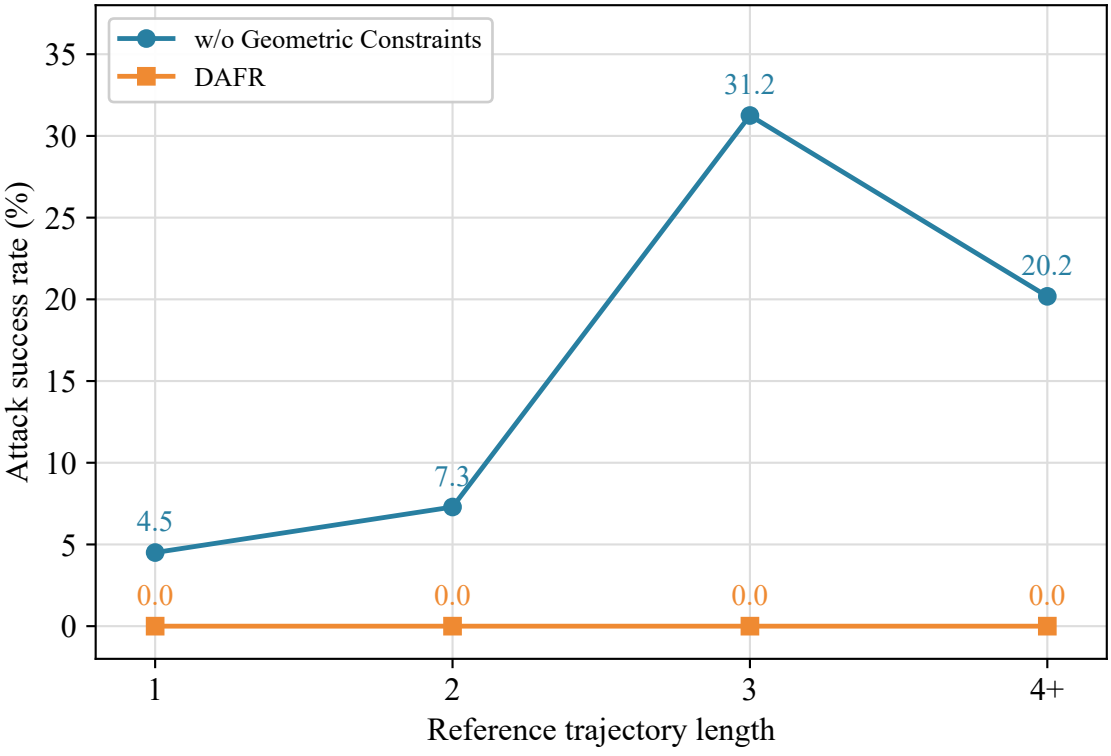


AgentDojo 中几何约束的安全收益与参考轨迹长度。采用 DeepSeek V4 Flash 的归档消融记录，按官方参考解的工具调用数分为 1、2、3、至少 4 步；每组分别包含 10、20、9、32 个用户任务，对应 111、192、64、218 次攻击执行，两个配置使用相同任务与攻击。ASR 按组内攻击执行记录求平均。去掉几何约束时，各组 ASR 为 4.5%、7.3%、31.2%、20.2%；完整 DAFR 各组均为 0%。这是一项跨任务的长度分组分析，各组领域与任务组成不同，不表示只增加步骤就会产生同等幅度的变化。