Overview of the Evaluated AgentDojo Subset

Domain	Tools	Tasks		Avg. Calls	
		User	Attack	Clean	Attack
Workspace	24	14	196	3.64	3.78
Slack	11	21	105	7.95	8.48
Travel	28	20	140	8.45	8.12
Banking	11	16	144	4.81	5.18
Overall	**18.35**	**71**	**585**	**6.54**	**6.01**

AgentDojo v1.2.2 实际评测子集概览，模型为 DeepSeek V4 Flash。User 为不同用户任务数，Attack 为实际评测的任务—攻击组合数。Avg. Calls 为完整 DAFR 的平均工具调用请求数，计入被防御层拦截的请求及成功、失败执行，按执行记录平均；Clean 与 Attack 分别统计干净和攻击条件。Tools 为各环境可用工具数；Overall 的工具数按用户任务数加权平均。