Overview of the Evaluated ASB Subset

Domain	Tools	Tasks		Avg. Calls	
		User	Attack	Clean	Attack
Finance	3	5	20	—	2.40
Legal	3	5	20	—	2.60
Medical	3	5	20	—	2.10
Education	3	5	20	—	1.95
Psychology	3	5	20	—	1.80
E-commerce	3	5	20	—	2.40
Aerospace	3	5	20	—	2.65
Academic Search	3	6	24	—	2.75
Autonomous Driving	3	5	20	—	2.60
System Administration	3	5	20	—	2.60
Overall	**3.00**	**51**	**204**	**—**	**2.39**

ToolSafe-ASB 实际评测子集概览，模型为 DeepSeek V4 Flash。User 为不同用户任务数，Attack 为实际评测的任务—攻击组合数。Avg. Calls 为完整 DAFR 的平均工具调用请求数，计入被防御层拦截的请求及成功、失败执行，按执行记录平均；Clean 与 Attack 分别统计干净和攻击条件。每个攻击执行提供两个正常工具与一个攻击工具，Tools 为单次执行可见工具数。归档包含 204 次攻击执行，未提供对应干净执行，故 Clean 标为“—”。