## Overview of the Evaluated Datasets

| Benchmark | Domains | Avg. Tools | Tasks | | Avg. Calls | |
|---|---|---|---|---|---|---|
| | | | User | Attack | Clean | Attack |
| AgentDojo | 4 | 18.35 | 71 | 585 | 6.54 | 6.01 |
| ASB | 10 | 3.00 | 51 | 204 | — | 2.39 |
| Synthetic | 6 | 6.00 | 104 | 104 | 6.29 | 6.67 |

三套数据集在本文实际评测范围内的概览。Domains 为环境或代理类别数；Avg. Tools 为每个用户任务可见的平均工具数，按用户任务加权，ASB 包含每次执行注入的一个攻击工具。User 为不同用户任务数，Attack 为实际评测的任务—攻击组合数。Avg. Calls 为完整 DAFR 的平均工具调用请求数，计入被防御层拦截的请求及成功、失败执行，按执行记录平均；Clean 与 Attack 分别统计干净和攻击条件。AgentDojo 与 ASB 使用归档 DeepSeek V4 Flash 结果，合成数据使用 DeepSeek V4 Flash（0731）。ASB 无对应干净执行记录，标为“—”。调用数反映所用模型与防御配置的实测开销，不作为最短参考轨迹长度；各行描述实际评测子集，而非原基准全部规模。