合成数据资源开销

Method	Input Tokens ↓	Output Tokens ↓	Total Tokens ↓	Tool Calls ↓
No Defense	8,668.64	763.69	9,432.33	4.76
PIGuard	11,658.41	796.92	12,455.33	6.28
ProtectAI	11,616.72	791.91	12,408.63	6.28
Progent	25,066.77	2,671.94	27,738.71	5.46
DRIFT	32,963.82	1,305.77	34,269.60	4.01
DAFR	12,634.76	920.43	13,555.20	6.48

在与合成主表相同的 104 个配对任务上统计开销，每种方法共执行 208 次。表中数值均为单次执行的平均值，保留两位小数。
Input Tokens、Output Tokens 包含 agent 规划及防御方法产生的全部大模型调用；Total Tokens 为输入与输出之和，按未舍入数值计算。
Tool Calls 为平均工具调用次数，包含被防御层拒绝的有效请求；主表与消融表中的 Total Tool Calls 则为总数。